

# Introducción a Azure

Rodrigo Blanco Betes. Alfa Formación

Enero del 2026

- 1 Introducción a Azure
- 2 Primeras prácticas
- 3 Procesamiento de datos
- 4 Visualización
- 5 Almacenamiento
- 6 Procesamiento en tiempo real
- 7 Gobierno del dato

- Organización de recursos y servicios en la nube
- Gestión de costes, entornos y despliegues
- Recursos principales:
  - Cuentas
  - Resource Groups
  - Virtual Machines
  - AKS

- Punto de partida para consumir servicios en Azure
- Asociadas a suscripción, facturación y control de acceso
- Permiten:
  - Monitorizar costes
  - Asignar presupuestos
  - Controlar el uso por equipos o proyectos
- Base para la gobernanza y la trazabilidad del gasto

- Contenedor lógico para agrupar recursos relacionados
- Facilitan la organización según distintos criterios:
  - Entornos: desarrollo, pruebas, producción
  - Funcionalidad: frontend, backend, datos
  - Área o centro de costes
- Simplifican la administración, permisos y eliminación conjunta

- Servicio de computación IaaS en Azure
- Permite desplegar servidores con control completo del sistema operativo
- Casos de uso habituales:
  - Aplicaciones legacy
  - Entornos de laboratorio
  - Servicios que requieren configuración específica

- Azure Kubernetes Service
- Plataforma gestionada para ejecutar contenedores orquestados con Kubernetes
- Reduce la complejidad operativa del clúster
- Adecuado para:
  - Aplicaciones distribuidas
  - Microservicios
  - Despliegues escalables y resilientes

- Identificación de suscripciones y responsables
- Revisión del consumo y control presupuestario
- Buenas prácticas:
  - Etiquetado de recursos
  - Separación por proyectos o departamentos
  - Seguimiento periódico del gasto



# Uso práctico de Resource Groups

- Crear grupos de recursos alineados con la estructura del proyecto
- Separar recursos por entorno:
  - rg-dev
  - rg-test
  - rg-prod
- Aplicar nomenclatura consistente
- Facilitar mantenimiento y limpieza de recursos

# Virtual Machine: creación y configuración

- Selección de imagen, tamaño y red
- Configuración inicial:
  - Sistema operativo
  - Credenciales de acceso
  - Reglas de red y puertos
  - Discos y monitorización
- Validación de conectividad y estado operativo

- Apagado y revisión previa del recurso
- Copia o respaldo de datos necesarios
- Eliminación controlada de:
  - Máquina virtual
  - Discos asociados
  - Interfaces de red e IP públicas
- Objetivo: evitar costes residuales y recursos huérfanos

# AKS: creación y configuración

- Creación del clúster y definición de nodos
- Configuración de red, identidad y escalado
- Despliegue inicial de cargas de trabajo en contenedores
- Revisión de:
  - Acceso al clúster
  - Estado de nodos y pods
  - Integración con monitorización

- Revisión de servicios y cargas desplegadas
- Exportación o migración de configuraciones necesarias
- Eliminación del clúster y recursos asociados
- Verificación final para evitar consumos innecesarios

- Azure permite organizar infraestructura de forma flexible y gobernada
- Los Resource Groups ayudan a estructurar recursos y costes
- Las Virtual Machines ofrecen control total sobre entornos IaaS
- AKS facilita la ejecución y operación de contenedores a escala
- La creación, configuración y decomisionado forman parte del ciclo de vida operativo

- Flujo de datos estructurado en varias fases
- Separación por capas para facilitar mantenimiento y trazabilidad
- Etapas principales del procesamiento:
  - Extracción
  - Ingesta
  - Limpieza
  - Generación de tablonos
  - Construcción del modelo de explotación

# Extracciones: origen a Blob

- Obtención de datos desde los sistemas de origen
- Posibles fuentes:
  - Bases de datos
  - APIs
  - Sistemas externos
  - Ficheros
- Los datos se almacenan inicialmente en almacenamiento Blob
- Objetivo: disponer de una copia inicial sin transformaciones



# Ingesta: Blob a Staging

- Movimiento de datos desde Blob hacia la capa *staging*
- Zona intermedia para preparar el procesamiento
- Características principales:
  - Datos cercanos al formato original
  - Preparados para su transformación
  - Control de versiones o particiones

# Limpieza con Spark: Staging a Golden

- Procesamiento de datos mediante Apache Spark
- Aplicación de transformaciones de calidad:
  - Eliminación de registros inválidos
  - Normalización de formatos
  - Tratamiento de valores nulos
  - Validaciones de integridad
- Resultado almacenado en la capa *golden*

# Generación de tableros con Spark

- Construcción de datasets agregados o enriquecidos
- Combinación de distintas fuentes de datos
- Operaciones habituales:
  - Joins
  - Agregaciones
  - Cálculo de métricas
- Los resultados se almacenan en la capa *golden*

# Modelo de explotación: Golden a Silver

- Generación de estructuras optimizadas para análisis
- Procesamiento mediante Spark
- Organización orientada a consumo analítico
- Características:
  - Datos consolidados
  - Estructuras optimizadas para consultas
  - Preparación para herramientas de BI o analítica

# Modelo de explotación: Golden a Cosmos

- Publicación de datos hacia Azure Cosmos DB
- Orientado a aplicaciones operacionales o APIs
- Ventajas:
  - Baja latencia
  - Alta escalabilidad
  - Acceso directo desde aplicaciones
- Los datos proceden de la capa *golden*

# Resumen del flujo de procesamiento

- Extracción de datos desde sistemas origen
- Ingesta inicial en almacenamiento intermedio
- Procesamiento y limpieza mediante Spark
- Generación de datasets enriquecidos
- Publicación de modelos para analítica y aplicaciones

- La visualización permite analizar el estado de los sistemas y explotar los datos procesados
- En entornos Azure, las herramientas de visualización suelen cubrir:
  - Monitorización operativa
  - Observabilidad de infraestructura y aplicaciones
  - Exploración y análisis de datos
- Herramientas principales:
  - Kibana
  - Grafana
  - Notebooks

- Herramienta orientada a exploración y visualización de datos indexados
- Uso habitual junto con Elasticsearch
- Permite:
  - Crear dashboards
  - Analizar logs
  - Investigar incidencias
  - Realizar búsquedas sobre grandes volúmenes de información
- En Azure puede integrarse en arquitecturas de observabilidad y análisis de logs



- Plataforma de visualización orientada a métricas y monitorización
- Muy útil para cuadros de mando técnicos y operativos
- Permite:
  - Visualizar series temporales
  - Supervisar infraestructura
  - Monitorizar aplicaciones y pipelines
  - Centralizar indicadores de distintos orígenes
- En Azure puede conectarse con servicios de monitorización y fuentes de datos diversas

- Entorno interactivo para exploración, transformación y análisis de datos
- Permiten combinar:
  - Código
  - Resultados
  - Visualizaciones
  - Documentación
- Uso habitual en Azure para:
  - Análisis exploratorio
  - Desarrollo con Spark
  - Validación de datasets
  - Prototipado de modelos

- Kibana facilita la exploración de logs y eventos
- Grafana está orientado a métricas y monitorización
- Los notebooks permiten análisis interactivo y desarrollo de procesos de datos
- En Azure, estas herramientas complementan la explotación y la observabilidad de la plataforma

# Almacenamiento en Azure

- El almacenamiento es una pieza central en cualquier arquitectura de datos
- Azure ofrece distintos modelos según el tipo de información y su uso
- Opciones principales:
  - Modelo SQL
  - Data Lake
  - Storage
  - Cosmos DB
- Cada una responde a necesidades diferentes de estructura, escalabilidad y acceso

- Almacenamiento relacional orientado a datos estructurados
- Basado en tablas, relaciones, claves e integridad referencial
- Adecuado para:
  - Aplicaciones transaccionales
  - Modelos normalizados
  - Consultas SQL
  - Reporting estructurado
- En Azure suele emplearse cuando se necesita consistencia y esquema definido

- Repositorio escalable para grandes volúmenes de datos
- Admite datos estructurados, semiestructurados y no estructurados
- Organización habitual por capas:
  - **Landing**: recepción inicial de datos
  - **Golden**: datos limpios, validados y enriquecidos
  - **Silver**: datos preparados para explotación o consumo específico
- Base habitual para arquitecturas analíticas modernas en Azure

- Zona de entrada de datos procedentes de sistemas origen
- Conserva la información con mínima transformación
- Objetivos:
  - Mantener trazabilidad
  - Preservar el dato original
  - Facilitar reprocesados
- Es la primera parada en el flujo de ingesta dentro del Data Lake

- **Golden:**

- Datos depurados y consolidados
- Resultado de procesos de limpieza y enriquecimiento

- **Silver:**

- Datos orientados a consumo
- Preparados para análisis, explotación o integración con otros sistemas

- Estas capas ayudan a separar el dato bruto del dato de negocio



- Azure Storage proporciona distintos servicios según el tipo de acceso requerido
- **Blob Storage:**
  - Orientado a objetos
  - Adecuado para ficheros, datos masivos, backups y datasets
- **File Storage:**
  - Comparte archivos mediante estructura tipo sistema de ficheros
  - Útil para recursos compartidos entre aplicaciones o servidores

- Servicio de almacenamiento de objetos en Azure
- Muy utilizado en arquitecturas de datos y analítica
- Casos de uso:
  - Ingesta de datos
  - Almacenamiento de ficheros de entrada y salida
  - Persistencia de datos intermedios
  - Integración con pipelines y procesos Spark

- Servicio orientado a compartición de archivos
- Permite montar recursos compartidos en entornos Windows o Linux
- Adecuado para:
  - Carpetas compartidas
  - Aplicaciones legacy
  - Intercambio de ficheros entre servicios
- Complementa al almacenamiento tipo Blob cuando se necesita acceso tipo fichero

- Base de datos NoSQL distribuida globalmente
- Diseñada para alta disponibilidad, baja latencia y escalabilidad horizontal
- Modelos mencionados:
  - API SQL
  - API MongoDB
- Adecuada para aplicaciones con necesidades de acceso rápido y flexible a los datos

- **API SQL:**
  - Modelo documental nativo
  - Consultas sobre documentos JSON
  - Muy utilizada en desarrollos cloud nativos
- **API MongoDB:**
  - Compatible con el ecosistema y herramientas de MongoDB
  - Facilita migraciones o integraciones con aplicaciones existentes
- Ambas permiten trabajar con datos semiestructurados en Azure

- El modelo SQL cubre necesidades relacionales y estructuradas
- El Data Lake organiza el ciclo de vida del dato en distintas capas
- Blob y File resuelven necesidades diferentes de almacenamiento en Azure
- Cosmos DB ofrece una alternativa NoSQL escalable para aplicaciones modernas

# Arquitectura de datos en tiempo real

- El procesamiento en tiempo real permite analizar datos según se generan
- Se utiliza en escenarios donde la latencia debe ser mínima
- Ejemplos de uso:
  - IoT y sensores
  - Monitorización de sistemas
  - Procesamiento de eventos
  - Analítica operativa
- En Azure, el flujo suele incluir ingestión de eventos, procesamiento streaming y almacenamiento

- Herramienta de programación visual basada en flujos
- Permite integrar dispositivos, APIs y servicios cloud
- Uso habitual en entornos IoT:
  - Conectar sensores o dispositivos
  - Transformar eventos
  - Enviar datos a servicios de Azure
- Facilita la creación rápida de pipelines de eventos



- Servicio gestionado para comunicación con dispositivos IoT
- Permite conectar y gestionar miles o millones de dispositivos
- Funcionalidades principales:
  - Ingesta de telemetría
  - Gestión de dispositivos
  - Comunicación bidireccional
  - Seguridad y autenticación
- Punto de entrada habitual para datos procedentes de sensores

- Plataforma de ingestión de eventos a gran escala
- Diseñada para manejar grandes volúmenes de datos en streaming
- Características principales:
  - Alta capacidad de ingestión
  - Procesamiento distribuido
  - Integración con servicios de análisis
- Muy utilizada como buffer entre productores de eventos y sistemas de procesamiento

- Extensión de Apache Spark para procesamiento de datos en streaming
- Permite analizar flujos de eventos en tiempo casi real
- Funcionalidades:
  - Transformación de datos
  - Agregaciones en streaming
  - Cálculo de métricas en tiempo real
- Puede consumir eventos desde Event Hub u otras fuentes

- Base de datos NoSQL distribuida utilizada para persistir resultados
- Adecuada para escenarios de baja latencia
- En arquitecturas streaming permite:
  - Guardar resultados procesados
  - Servir datos a aplicaciones en tiempo real
  - Escalar horizontalmente con gran volumen de eventos

# Notebooks en procesamiento streaming

- Permiten desarrollar y validar pipelines de procesamiento
- Usados habitualmente en entornos Spark
- Utilidades:
  - Desarrollo de lógica de transformación
  - Análisis exploratorio de flujos de datos
  - Monitorización y validación de resultados

# Flujo típico de procesamiento en tiempo real

- Generación de eventos desde dispositivos o aplicaciones
- Ingesta mediante IoT Hub o Event Hub
- Procesamiento en streaming con Spark
- Persistencia de resultados en sistemas de almacenamiento
- Visualización o explotación de la información

- El gobierno del dato define cómo se gestionan los datos dentro de una organización
- Su objetivo es garantizar:
  - Calidad del dato
  - Seguridad
  - Cumplimiento normativo
  - Uso correcto de la información

# Elementos clave del gobierno del dato

- Definición de responsables y roles sobre los datos
- Gestión de la calidad y validación de información
- Control de accesos y seguridad
- Catalogación y documentación de datasets
- Seguimiento del ciclo de vida del dato



- Azure proporciona herramientas para gestionar el ciclo de vida del dato
- Permite:
  - Controlar accesos a los recursos
  - Auditar el uso de los datos
  - Catalogar y descubrir información
  - Aplicar políticas de seguridad
- El gobierno del dato es esencial en plataformas de datos empresariales

- El procesamiento en tiempo real permite analizar eventos según se generan
- Azure ofrece servicios para ingestión, procesamiento y almacenamiento streaming
- Cosmos DB facilita el acceso rápido a los resultados
- El gobierno del dato garantiza calidad, seguridad y control sobre la información